# Założenia projektowe

1. **Skład zespołu**:
    a. Marianna Tybura 240826
    b. Zuzanna Zając 240843
    c. Jakub Sońta 259166
    d. Krzysztof Kaniuka 259158

2. **Cel:** Predykcja wyników egzaminów studentów przy użyciu regresji

3. **Zbiór danych:** Exam Score Prediction Dataset (20 tys. Rekordów)

4. **Technologia**:
    a. Python
        i. Pandas
        ii. Matplotlib
        iii. Seaborn
        iv. Sklearn
        v. Numpy

5. **Model regresji:** XGB Regressor

6. **Cechy:**
    1. Age

Przedział wiekowy uczniów od 17 do 24 lat

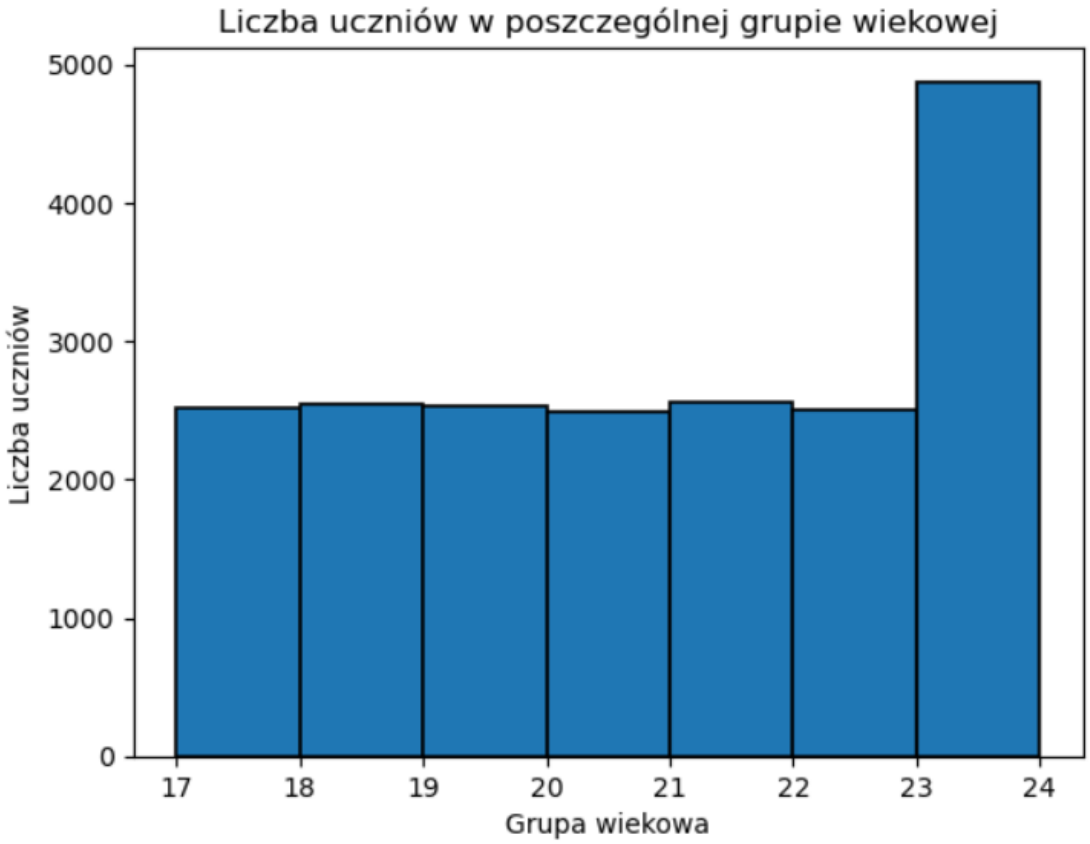

2. Gender

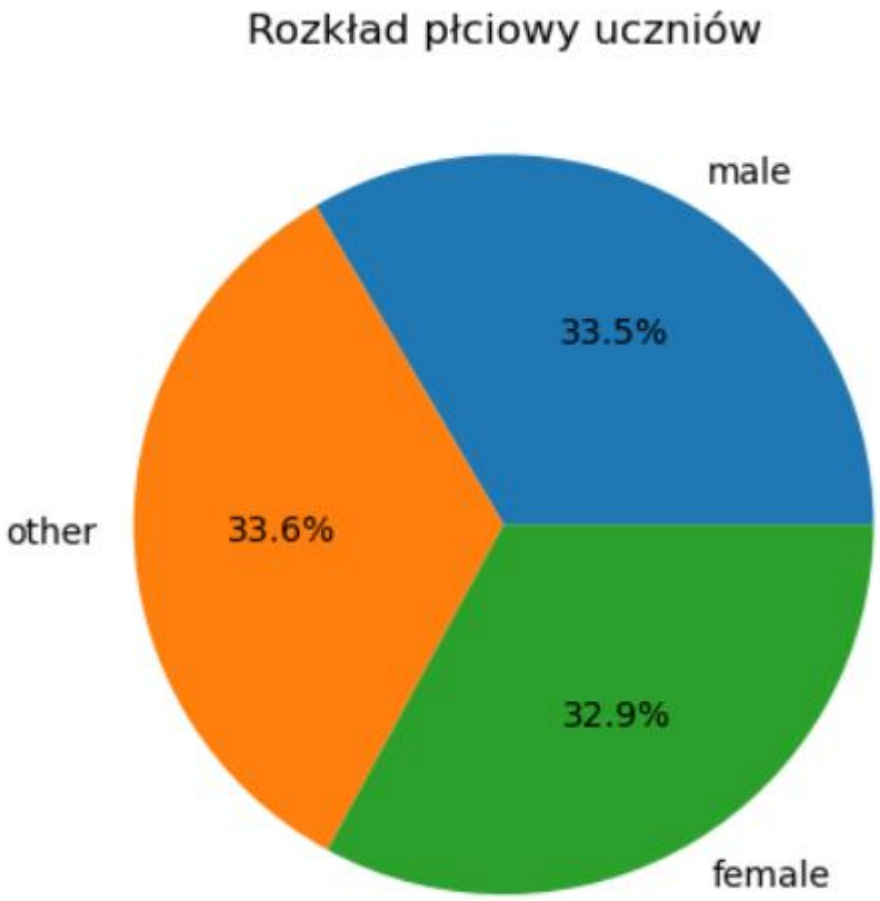


3. Course

   Programy studiów, na które uczęszczali uczniowie

   - Diploma - kwalifikacja po programie dyplomowym
   - Bca - licencjat z zastosowań informatyki
   - B.sc - licencjat nauk ścisłych/przyrodniczych
   - B.tech - licencjat/inżynier w dziedzinie technologii
   - Bba - licencjat z zarządzania
   - Ba - licencjat nauk humanistycznych/społecznych
   - B.com- licencjat z handlu/ekonomii

   Poniżej widać że zbiór danych jest zbalansowany w kontekście tej cechy

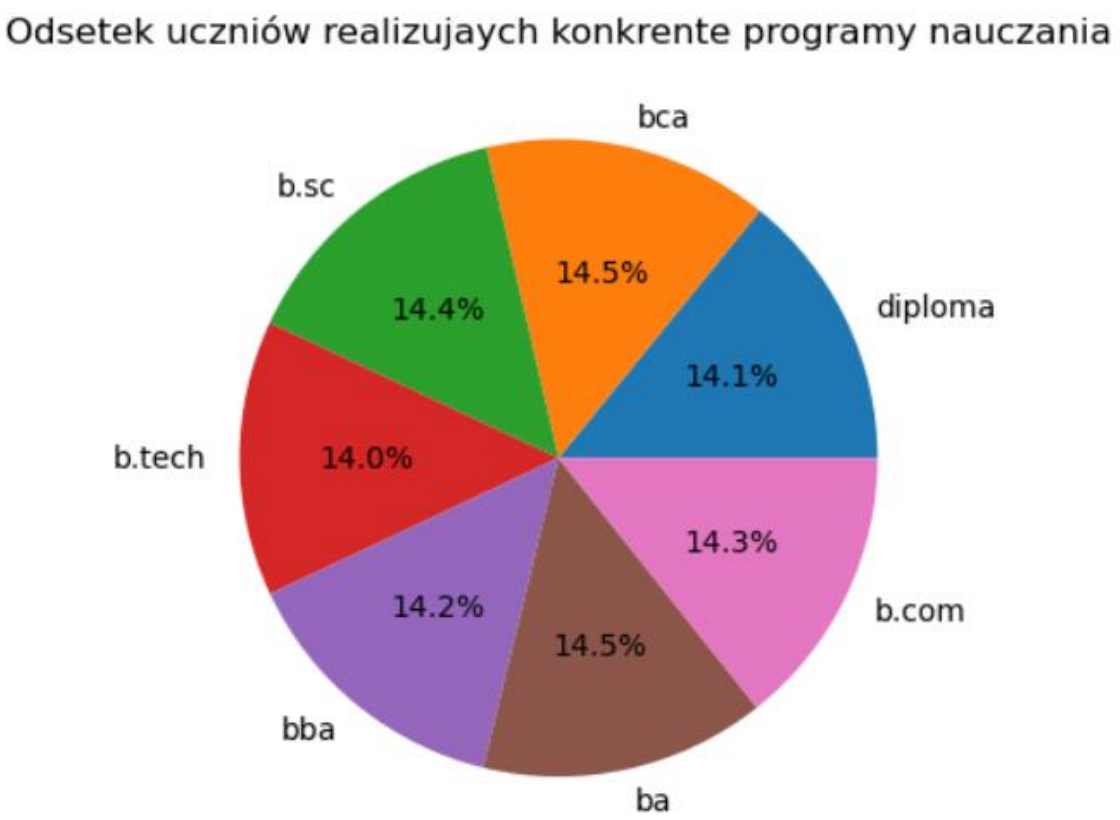


4. Study hours

   Liczba godzin poświęconych nauce (cecha numeryczna)

5. Class attendance

   Obecność na zajęciach mierzona w skali od 1 do 100 (cecha numeryczna)

6. Internet access

   Większość uczniów miała dostęp do Internetu

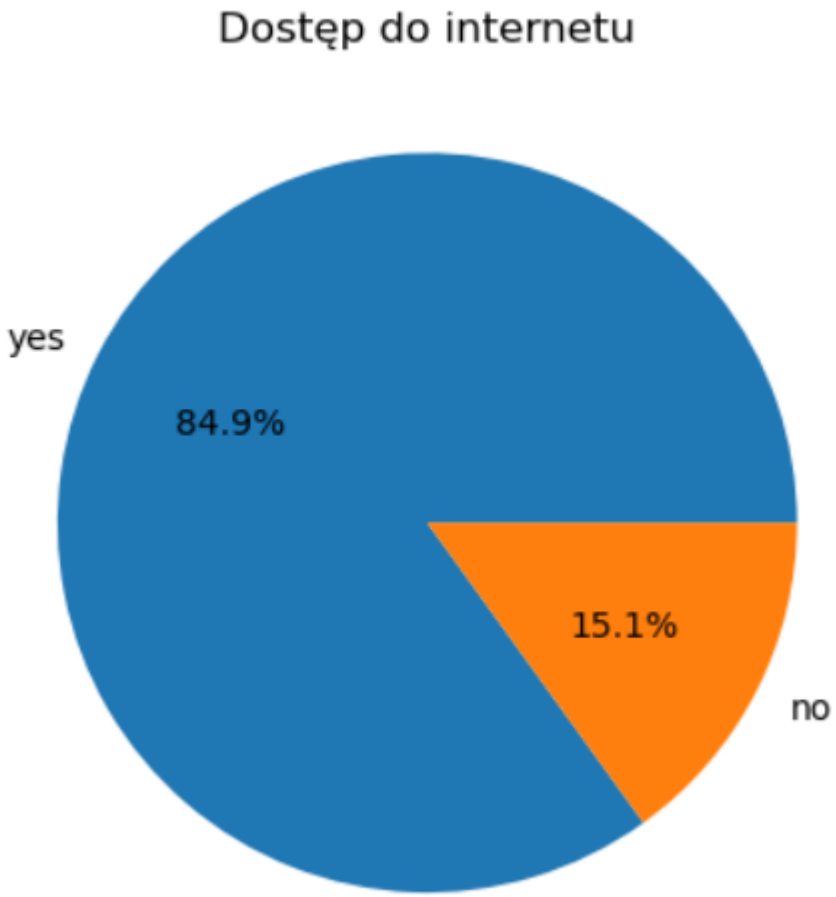


Cecha ta nie miała jednak dużego wpływu na rezultaty egzaminu

```
Mediana uczniów mających dostęp do Internetu 62.6
Mediana uczniów mających dostęp do Internetu 62.650000000000006
```

7. Sleep hours

   Prawie 1/3 uczniów spała mniej niż 6 godzin

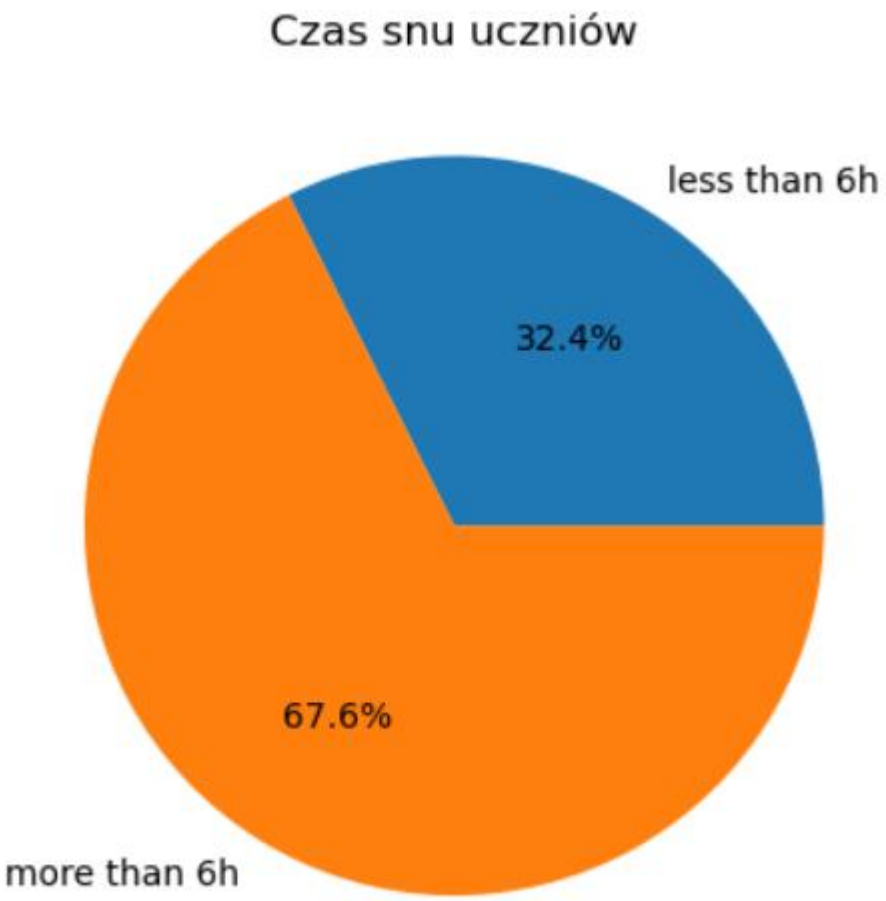


Długość snu ma większy wpływ na wynik egzaminu niż dostęp do Internetu

```
Mediana uczniów śpiących mniej niż 6 godzin 59.8
Mediana uczniów śpiących 6 lub więcej godzin 64.1
```

8. Sleep quality

   Zbiór danych jest zbalansowany dla tej zmiennej

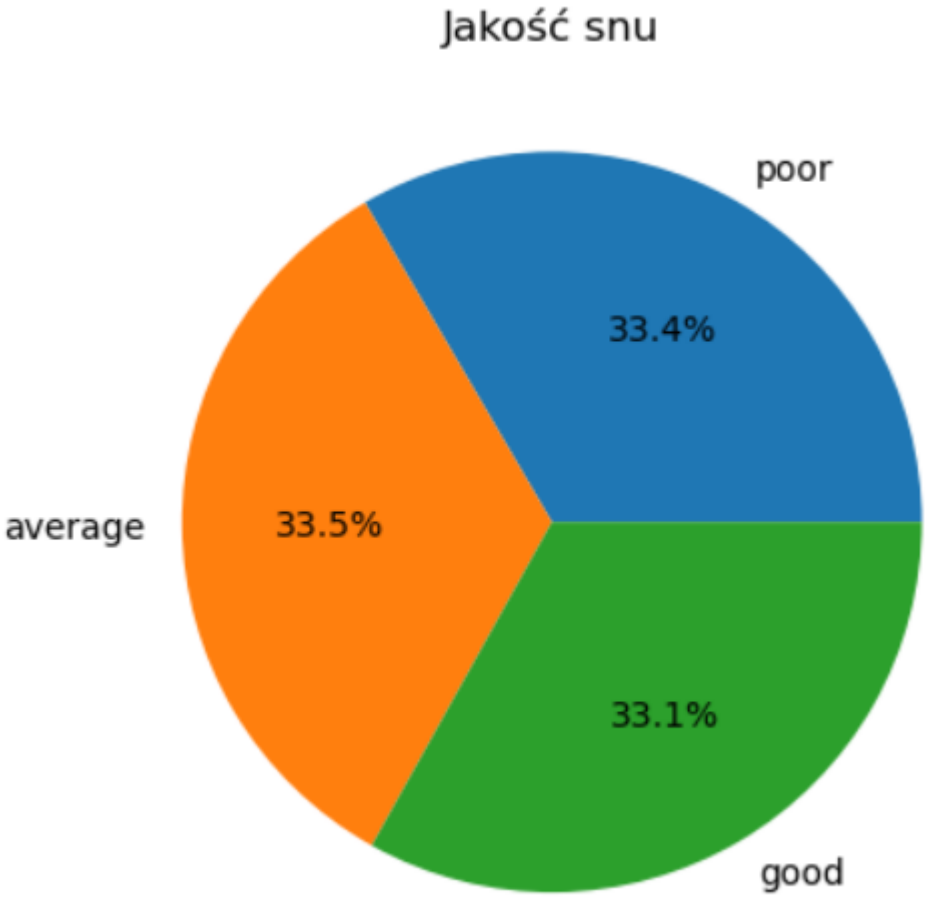


9. Study method

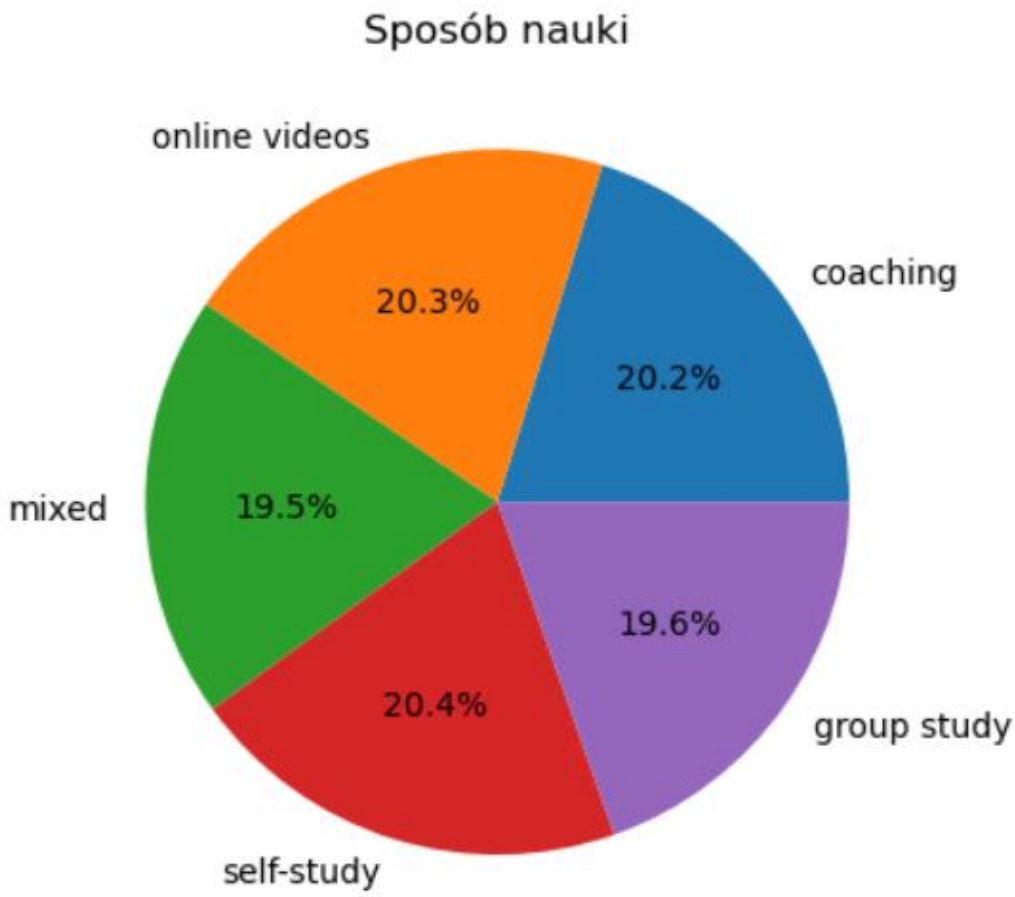


10. Facility Rating

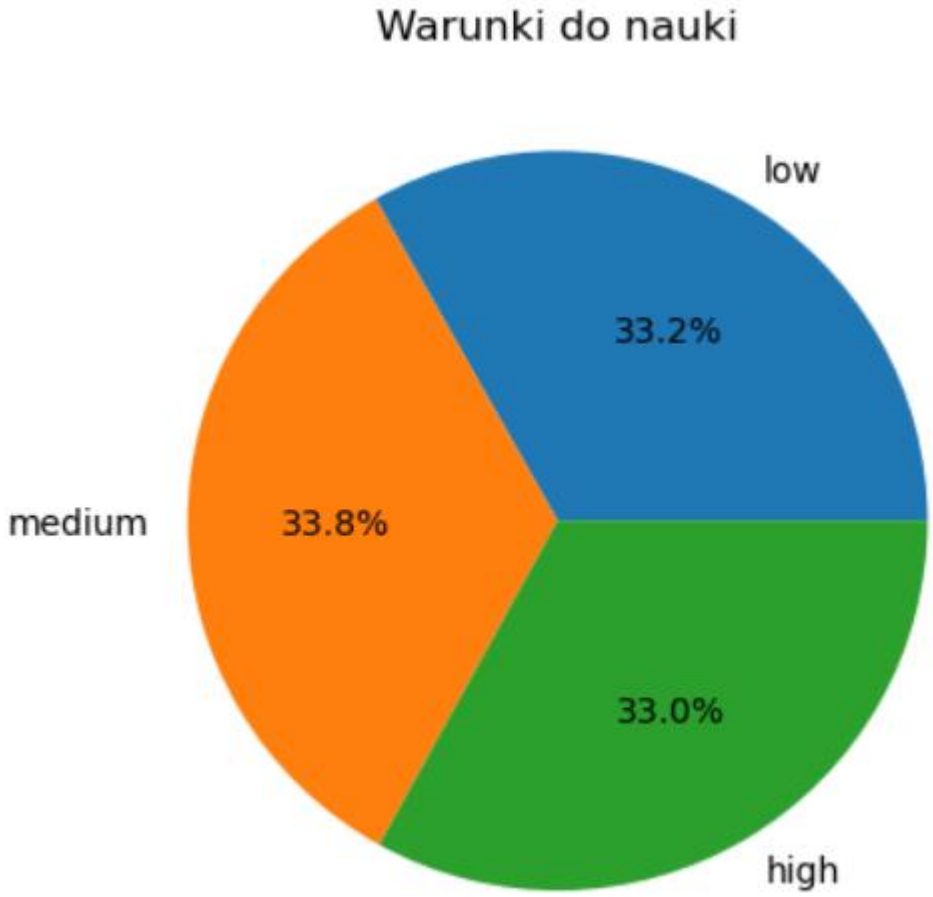
Warunki do nauki
low
33.2%
medium
33.8%
33.0%
high

11. Exam Dificulty

Niemal połowa egzaminów oceniana była jako średnio-trudna

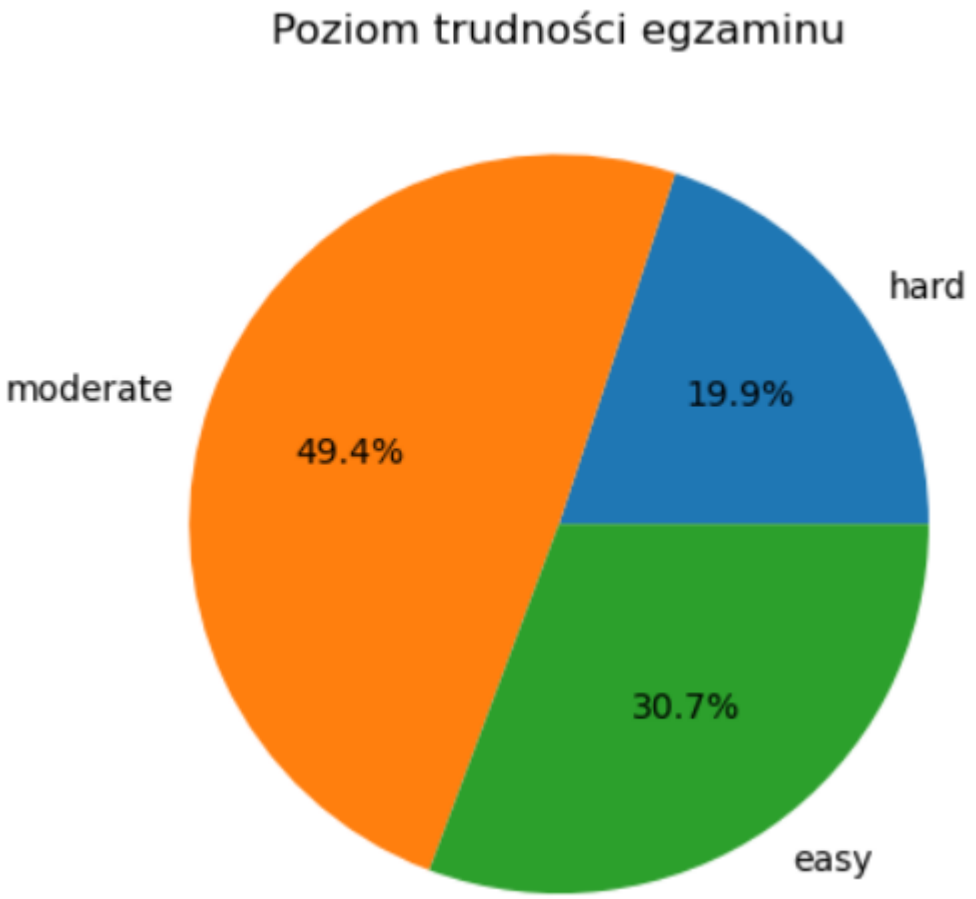


**12. Exam score – zmienna zależna zbioru**

Wynik egzaminu podany w skali od 0 do 100 (wartość numeryczna

## 7. Omówienie modelu predykcyjnego

Pierwszym krokiem, po wczytaniu zbioru danych z pliku, było uzupełnienie braków danych. Dla wartości kategorycznych dokonano tego wartością modalną, a dla wartości numerycznych, wartością średnią.

```
df_full = pd.read_csv("Exam_Score_Dataset.csv")

for col in df_full.columns:
    if df_full[col].dtype == 'object':
        df_full[col] = df_full[col].fillna(df_full[col].mode()[0])
    else:
        df_full[col] = df_full[col].fillna(df_full[col].mean())
```

Następnie, usunięto ze zbioru kolumnę id, która nie niosła za sobą żadnej informacji w kontekście treningu modelu.

```
if 'student_id' in df_full.columns:
    df_full = df_full.drop(columns=['student_id'])
```

Zbiór danych podzielono na podzbiory treningowy i testowy. Ponadto wytyczono w zbiorze zmienną celu oraz wyróżniono wśród pozostałych cech bazowych cechy o charakterze numerycznym.

```
train_df = df_full.sample(frac=0.8, random_state=42).copy()
test_df = df_full.drop(train_df.index).copy()

train_df = train_df.reset_index(drop=True)
test_df = test_df.reset_index(drop=True)

TARGET = 'exam_score'
base_features = [col for col in train_df.columns if col != TARGET and train_df[col].dtype == 'object']
num_features = ['study_hours', 'class_attendance', 'sleep_hours']
```

W celu wstępnej obróbki podzbiorów danych, przygotowano funkcję preproces(df). W ramach tej funkcji, dokonano transformacji logarytmicznej oraz kwadratowej dla zmiennych numerycznych zbioru w celu zmniejszenia wpływu skośności rozkładu.

```
def preprocess(df):
    df_temp = df.copy()

    for col in num_features:
        if col in df_temp.columns:
            df_temp[f'log_{col}'] = np.log1p(df_temp[col])

    for col in num_features:
        if col in df_temp.columns:
            df_temp[f'{col}_sq'] = df_temp[col] ** 2
```

Na podstawie obserwacji zbioru danych, dostrzeżono również potencjał zmiennych **study_hours**, **class_attendance** oraz **sleep_hours** na bazie których zbudowana została funkcja celu dla danego zbioru danych.

```python
df_temp['feature_formula'] = (
    5.9 * df_temp['study_hours'] +
    0.3 * df_temp['class_attendance'] +
    1.4 * df_temp['sleep_hours'] + 4.7819
)
```

*1 Funkcja Celu*

W kolejnym krokach skupiono się na treningu modelu przy użyciu regressora XGBoost (gradient boosting drzew decyzyjnych).

```python
# Model Training
xgb_params = {
    'n_estimators': 10000,
    'learning_rate': 0.007,
    'max_depth': 7,
    'subsample': 0.8,
    'num_parallel_tree': 2,
    'reg_lambda': 3,
    'colsample_bytree': 0.7,
    'tree_method': 'hist',
    'random_state': 42,
    'early_stopping_rounds': 100,
    'eval_metric': 'rmse',
    'enable_categorical': True,
    'n_jobs': -1
}
```

*2 Parametry wejściowe dla regresora XGBoost*

Postawiono na długi horyzont boostingowy *(n_estimators = 10000)* z małym krokiem *(learning_rate = 0.007)* oraz umiarkowaną głębokością drzew decyzyjnych *(max_depth = 7)*

Trening wykonano w 5 iteracjach, w których trenowano model na 4/5 danych wejściowych danego foldu, a 1/5 służyła jako podzbiór walidacyjny. Dla każdej iteracji zmierzono wskaźniki RMSE oraz R^2 (dla foldów), a na koniec ustalono wartości tych wskaźników dla całego zbioru danych.

```
test_predictions = []
oof_predictions = np.zeros(len(X))
kf = KFold(n_splits=5, shuffle=True, random_state=42)

importances_list = []

for fold, (train_index, val_index) in enumerate(kf.split(X, y)):
    print(f"\n--- Fold {fold+1} ---")

    X_train_fold, X_val = X.iloc[train_index], X.iloc[val_index]
    y_train_fold, y_val = y.iloc[train_index], y.iloc[val_index]

    model = xgb.XGBRegressor(**xgb_params)

    model.fit(
        X_train_fold,
        y_train_fold,
        eval_set=[(X_val, y_val)],
        verbose=500
    )

    fold_importance = pd.DataFrame()
    fold_importance["feature"] = X.columns
    fold_importance["importance"] = model.feature_importances_
    fold_importance["fold"] = fold + 1
    importances_list.append(fold_importance)

    val_preds = model.predict(X_val)
    oof_predictions[val_index] = val_preds

    rmse = np.sqrt(mean_squared_error(y_val, val_preds))
    r2 = r2_score(y_val, val_preds)

    print(f"Fold {fold+1} RMSE: {rmse:.4f}")
    print(f"Fold {fold+1} R2:   {r2:.4f}")

    test_preds = model.predict(X_test)
    test_predictions.append(test_preds)
```

8. **Rezultaty**

$R^2$ = 0.7235 oznacza, że model wyjaśnia około 72% wariancji wyników egzaminu, co wskazuje na solidną moc predykcyjną

RMSE = 9.9113 należy interpretować względem skali *exam_score*. Jeśli skala wynosi 0–100, średni błąd rzędu ~10 punktów jest umiarkowany: wystarczy do analiz zbiorowych, ale może być graniczny przy decyzjach indywidualnych

```
OVERALL RMSE: 9.9113
OVERALL R2:   0.7235
```

Dobrze spisała się również wyprowadzona ręcznie cecha, stanowiąca funkcję celu, wyprzedzając bazowe cechy zbioru w kontekście użyteczności przy treningu modelu